Pronóstico de la Demanda Minorista de Muebles en Colombia: Regresión Lineal Múltiple Aplicada a un Panel de Mes × Ciudad × Subsector

Joshua Samad Trujillo Lagos y Juan Andrés Zambrano Mora

Pregrado en Ciencia de Datos Universidad Externado de Colombia

Machine Learning I (2026-2)

Profesor: Alber Montenegro

Entrega Final — Fase 3: Consolidación, despliegue y comunicación de resultados

Resumen

Este documento corresponde a la Entrega Final (Fase 3) del Proyecto Integrador de Machine Learning I. Se seleccionó y evaluó el modelo final —la regresión lineal múltiple— a partir de la comparación validada de la Segunda Entrega, y se midió su desempeño por única vez sobre el conjunto de prueba de 1.080 filas, reservado intacto desde la Fase 2. El modelo obtuvo un MAPE de 4,18 % y un R^2 de 0,873 en prueba, frente a un MAPE de 4,89 % reportado por İnce y Taşdemir (2024) para la regresión lineal múltiple en el artículo base. La línea base naïve estacional alcanzó un MAPE de 10,67 %, de modo que el modelo la supera en 6,50 puntos. Se implementó un despliegue básico en Streamlit que aplica el mismo Pipeline de preprocesamiento que el entrenamiento. Se discuten las limitaciones —datos simulados, ausencia del pronóstico a 36 meses por alcance del curso y la multicolinealidad heredada del artículo— y las líneas de proyección hacia Machine Learning II.

Palabras clave: regresión lineal múltiple, pronóstico de demanda, validación cruzada, despliegue, comercio minorista de muebles.

Modelo Final y Reproducción de los Objetivos del Artículo

El modelo final se seleccionó por el MAPE en validación (4,08 %), conforme a la guía del proyecto, que exige justificar la selección con base en las métricas, la estabilidad y el equilibrio entre desempeño e interpretabilidad (Universidad Externado de Colombia, 2026, sección 8.1). Se reentrenó con todo el conjunto de desarrollo (4.320 filas) y se evaluó una sola vez sobre la prueba (1.080 filas). Los resultados se comparan con el artículo en la Tabla 1.

Tabla 1

Desempeño del Modelo Final sobre la Prueba frente al Artículo

Métrica	**Modelo final (regresión lineal múltiple) — prueba**	**İnce y Taşdemir (2024)**
MAPE	4,18 %	4,89 % (cuerpo) / 3,47 % (resumen)
R^2	0,8729	0,7673 (ajustado 0,7409)
MAE / MAD	4,286	447,14 (MAD)
RMSE / MSD	5,378	646,09 (√417.422)
Umbral de desempeño	MAPE < 10 % → sobresaliente	MAPE < 10 % → sobresaliente

Nota. El artículo reporta MSD y MAD, nombres de Minitab para MSE y MAE respectivamente (İnce y Taşdemir, 2024). La línea base naïve estacional obtiene un MAPE de 10,67 % en prueba, que el modelo supera en 6,50 puntos.

Los dos objetivos del artículo se reproducen en el contexto local: la selección de predictores estadísticamente significativos y el pronóstico de la demanda con un MAPE por debajo del 10 %. La diferencia principal es el horizonte: aquí se evalúa sobre observaciones fuera de muestra del panel y no se emite un pronóstico a 36 meses, porque ese pronóstico en el artículo combina la regresión con Holt–Winters y ese método está fuera del alcance de Machine Learning I (Universidad Externado de Colombia, 2026, sección 2).

Se deja constancia de que el alcance de este trabajo es el objetivo de la regresión lineal múltiple —modelar y validar la demanda—, y que el método de Holt–Winters del artículo se considera únicamente como referencia externa, no como modelo reproducido.

Interpretación de Resultados

- Las variables más influyentes son importaciones de muebles e inicios de vivienda (signo positivo, en línea con las correlaciones de 0,714 y 0,731 del artículo) e índice de sentimiento del consumidor (signo negativo, −0,366 en el artículo). Población e IPP tienen efecto pequeño, como en el artículo, donde ambos presentan VIF altos.
- La estacionalidad (codificada por mes) y la bandera de pandemia capturan el pico de diciembre y la caída de 2020, reproduciendo la estructura de estacionalidad multiplicativa sin modelar series de tiempo.
- El modelo tiende a subpronosticar ligeramente, coherente con la asimetría del MAPE; en un problema de inventario eso implica un leve riesgo de desabastecimiento, por lo que se recomienda operar el pronóstico con un margen de seguridad o vigilar el sesgo con el RMSE.
- Las conclusiones son de asociación predictiva dentro del panel: ningún resultado autoriza una lectura causal, en concordancia con el alcance del propio artículo.

Despliegue Básico

Se implementó una aplicación funcional en Streamlit (https://streamlit.io/) que recibe las nueve entradas del modelo —cinco numéricas, la bandera de pandemia, ciudad, subsector y mes—, aplica el mismo Pipeline de preprocesamiento que en el entrenamiento y devuelve la demanda estimada en millones de USD (Universidad Externado de Colombia, 2026, sección 8.3). Se verificó la coherencia entre los datos de entrenamiento y los de uso: la aplicación espera

exactamente las columnas con las que se entrenó el modelo, y el escalamiento y la codificación están dentro del Pipeline guardado, no se recalculan en la interfaz.

- Ejecución: streamlit run despliegue_streamlit.py desde la carpeta del proyecto.
- Documentación: el archivo README describe dependencias, el orden de los scripts y la semilla 42.

Calidad, Limitaciones y Proyección

Limitaciones:

- Datos simulados con fundamento: reproducen la estructura generadora del artículo con correlaciones ancladas a fuentes citables, pero no son observaciones reales del mercado colombiano; los coeficientes son plausibles, no empíricos.
- El horizonte de pronóstico no se emite, por el alcance del curso respecto a Holt–Winters.
- Riesgo de sobreajuste controlado: la brecha entre validación (4,08 %) y prueba (4,18 %) es de 0,10 puntos, lo que indica generalización, aunque con un panel simulado la validación no sustituye datos reales.
- Multicolinealidad heredada del artículo: importaciones, inicios y sentimiento están correlacionados, con VIF de hasta 23 para el índice de precios al productor, lo que infla los errores estándar de los coeficientes sin invalidar la predicción.

Proyección:

- Anclar la simulación en datos reales del DANE (Encuesta Mensual de Comercio o microdatos de establecimientos) para sustituir los coeficientes asumidos por estimaciones empíricas.
- Incorporar el pronóstico a 36 meses una vez visto el tema de series de tiempo, o comparar el MAPE con el artículo declarando Holt–Winters como referencia externa.

- Proyección hacia Machine Learning II: ensambles y métodos no lineales para capturar interacciones no lineales, hoy fuera del alcance (Universidad Externado de Colombia, 2026, sección 8.4).

Conclusión

El proyecto reproduce con éxito el objetivo central del artículo de İnce y Taşdemir (2024) en un contexto colombiano: la regresión lineal múltiple vuelve a ser el modelo con mejor capacidad predictiva, con un MAPE de 4,18 % en prueba que se ubica bajo el umbral del 10 % que el artículo califica como sobresaliente y que supera a la línea base en 6,50 puntos. El flujo es reproducible y sin fuga de datos, y el despliegue en Streamlit cierra el ciclo completo del curso: formulación del problema, preprocesamiento, entrenamiento, validación y despliegue. Las limitaciones declaradas —datos simulados y alcance restringido respecto al pronóstico de series de tiempo— no afectan la validez de las conclusiones dentro del marco del curso.

Reproducibilidad del Trabajo

Todo el flujo del proyecto es reproducible de principio a fin: los datos se generan con la semilla 42, el entrenamiento, la validación y la selección del modelo se ejecutan con un único script, y el modelo final se guarda con joblib y se recarga sin pérdida en el despliegue. La verificación cruzada entre los resultados del informe y las salidas de los scripts confirma que cada cifra reportada proviene de la ejecución del código entregado. Los scripts entregados cubren las cinco etapas verificables —generación de datos, modelamiento, figuras, evaluación y despliegue— y el archivo README documenta dependencias, orden de ejecución y resultados.

Referencias

Dane. (2024). *Producto interno bruto por actividad económica* [Conjunto de datos]. https://www.dane.gov.co

İnce, M. N., & Taşdemir, Ç. (2024). *Forecasting retail sales for furniture and furnishing items through the employment of multiple linear regression and Holt–Winters models*. *Systems*, *12*(6), 219. https://doi.org/10.3390/systems12060219

Montenegro, A. (2026). *Guía del proyecto integrador: Machine Learning I*. Universidad Externado de Colombia.

Montenegro, A. (2026). *Retroalimentación de la primera entrega del proyecto integrador* [Información no publicada]. Universidad Externado de Colombia.

Pedregosa, G., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). *Scikit-learn: Machine learning in Python*. *Journal of Machine Learning Research*, *12*, 2825–2830.

Streamlit. (2024). *Streamlit: A faster way to build and share data apps* [Software]. https://streamlit.io

Universidad Externado de Colombia. (2026). *Microcurrículo: Machine Learning I*. Facultad de Ciencias.