PROYECTO INTEGRADOR · MACHINE LEARNING I · SEGUNDA ENTREGA

Guion del video

Pronóstico de la demanda minorista de muebles en Colombia

Fase 2: datos, modelamiento y validación

Santiago Bernal Rozo y Joshua Samad Trujillo Lagos

Prof. Alber Montenegro · Universidad Externado de Colombia · 2026

Cómo usar este guion

- Cada página trae la diapositiva, **lo que dices** y **la idea explicada fácil**.
- Primero lean «La idea» para entender; después digan «Lo que dices» **con sus palabras**. No hace falta memorizarlo palabra por palabra, y se nota cuando alguien lee.
- Cada diapositiva tiene un tiempo de referencia. El video completo dura unos **14 minutos**, contando las pausas.
- La línea «Rúbrica» dice qué criterio de la segunda entrega se está cumpliendo en ese momento.

Reparto y tiempos

#	Diapositiva	Habla	Tiempo
1	Portada	Joshua	0:35
2	Qué corregimos frente a la primera entrega	Joshua	0:50
3	El artículo: regresión lineal frente a Holt–Winters	Joshua	1:00
4	Nuestro problema: un panel de 5.400 filas	Joshua	0:55
5	Cómo simulamos los datos	Joshua	1:10
6	La simulación reproduce la estructura temporal	Joshua	0:55
7	Las correlaciones se parecen a las del artículo	Joshua	1:00
8	Un flujo sin fuga de información	Santiago	1:00
9	Primero, el piso: dos líneas base corridas	Santiago	0:35
10	Tres modelos del curso y su ajuste por validación cruzada	Santiago	0:50
11	La regresión lineal múltiple gana	Santiago	0:55
12	Por qué medimos con MAPE	Santiago	0:50
13	Los errores del mejor modelo no tienen sesgo	Santiago	0:55
14	Qué variables usa el modelo	Santiago	1:00
15	¿Aguanta si pronosticamos un año nuevo?	Santiago	1:05
16	Conclusiones	Los dos	0:50
	Total (Joshua 6:25 · Santiago 7:10 · los dos 0:50)		**14:25**

Dónde se cumple cada criterio de la rúbrica

Criterio (segunda entrega)	Qué mostramos	Diapositivas
Consolidación de los datos	Cómo se generó la simulación, con fuentes; verificación de la estructura temporal (tendencia, estacionalidad, pandemia) y de las relaciones (correlaciones); calidad y transformaciones.	4, 5, 6 y 7
Flujo sin fuga	Partición única con prueba sellada, validación cruzada y Pipeline que se ajusta solo con el entrenamiento; orden de las etapas y por qué evita la fuga.	8 (y 15)
Entrenamiento y comparación	Dos líneas base corridas, tres modelos del curso, ajuste de α y k por validación cruzada, comparación con variabilidad.	9, 10 y 11
Validación, métricas e interpretación	MAPE justificado por el costo, métricas complementarias, lectura de errores, variables relevantes, prueba de robustez y limitaciones.	11 a 15
Comunicación y sustentación	Reparto equilibrado: los dos explican una parte técnica completa y cierran juntos.	Todas; 16

Consejos para grabar

- Proyecten la presentación en pantalla completa y graben la voz (y si pueden, la cámara) de quien habla en cada parte. La rúbrica premia que **todo el equipo** domine el proyecto.
- Graben por bloques, una diapositiva a la vez, y dejen un segundo de silencio entre una y otra. Así es fácil cortar y repetir.
- Señalen con el cursor lo que están explicando: la diagonal, la barra, el rombo. El profesor sigue mejor el razonamiento.
- Hablen despacio: unas 140 palabras por minuto. Si van muy rápido, el video se acorta y se entiende menos.
- Revisen el audio en los primeros 20 segundos antes de grabar todo.
- No se pasen de 15 minutos. Si el profesor fijó otro límite, recorten en las diapositivas 3 y 10.

Antes de entregar: revisen la lista de la última página

El informe corregido, el repositorio y el video ya coinciden. La última página trae la lista de lo que deben revisar antes de grabar y entregar.

Diapositiva 1 de 16 · Portada

Joshua · 0:35



Lo que dices

«Hola, somos Joshua Trujillo y Santiago Bernal. Este es el video de la segunda entrega de nuestro Proyecto Integrador de Machine Learning I. Trabajamos el pronóstico de la demanda minorista de muebles en Colombia, a partir del artículo de İnce y Taşdemir, de 2024. En esta fase mostramos tres cosas: cómo construimos y verificamos los datos, cómo entrenamos los modelos sin fuga de información y qué tan bien pronostican.»

La idea, explicada fácil

Pronosticar la demanda es estimar cuánto se va a vender para comprar el inventario justo. Si una tienda compra de más, la bodega se llena de muebles quietos; si compra de menos, pierde ventas. Todo el proyecto busca reducir ese error.

Rúbrica: comunicación. Presentar al equipo y decir desde el principio qué se va a mostrar.

Diapositiva 2 de 16 · Qué corregimos frente a la primera entrega

Joshua · 0:50



Lo que dices

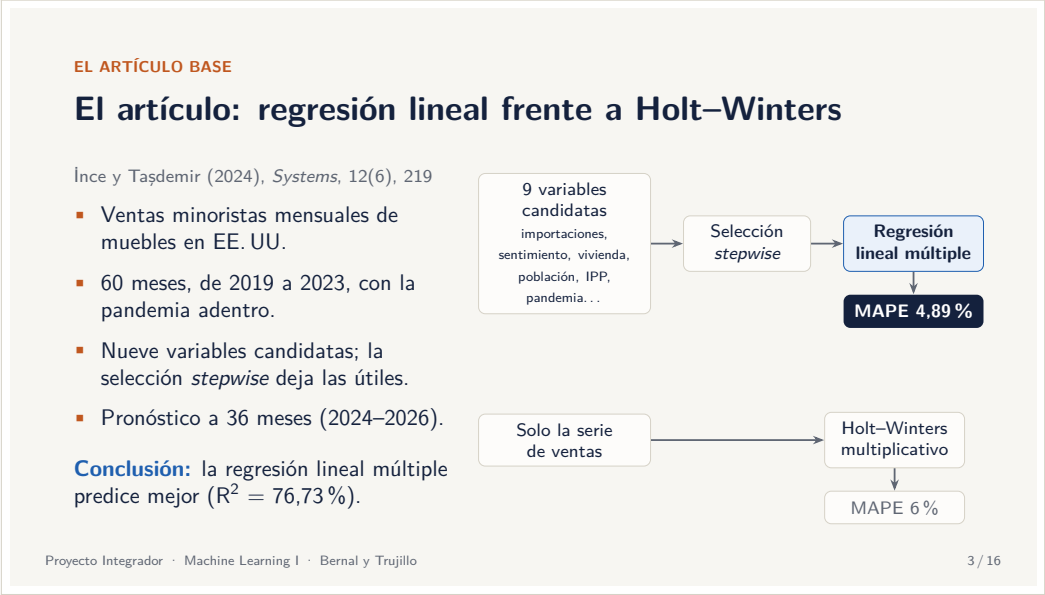
«En la primera entrega recibimos cinco observaciones y las corregimos todas. Uno: teníamos 60 datos y la guía pide al menos 5.000; ahora trabajamos con un panel de 5.400 filas. Dos: habíamos incluido modelos que no son del curso, como Holt–Winters; ahora solo usamos regresión lineal múltiple, Ridge y KNN. Tres: no había código; ahora hay scripts que cualquiera puede correr y obtener lo mismo, porque fijamos la semilla 42. Cuatro: la línea base estaba solo descrita; ahora la construimos y la corrimos. Y cinco: habíamos elegido el MAPE por costumbre; ahora lo justificamos por el costo del error en el inventario.»

La idea, explicada fácil

Semilla: es el número que fija el «azar» del computador. Con la misma semilla, los sorteos salen idénticos y cualquier persona obtiene los mismos resultados. Eso es lo que la guía llama reproducibilidad.

Rúbrica: comunicación y reproducibilidad. Mostrar que se atendió la retroalimentación da contexto a todo lo que sigue.

Diapositiva 3 de 16 · El artículo: regresión lineal frente a Holt–Winters Joshua · 1:00



Lo que dices

«El artículo base es de İnce y Taşdemir, publicado en la revista *Systems* en 2024. Ellos quieren pronosticar las ventas mensuales de muebles en Estados Unidos. Tienen 60 meses, de 2019 a 2023, así que la pandemia queda dentro de los datos. Comparan dos caminos. El primero es una regresión lineal múltiple: parten de nueve variables candidatas, como las importaciones de muebles o el sentimiento del consumidor, y con una selección paso a paso se quedan con las útiles. El segundo es Holt–Winters, que solo mira la historia de las ventas. Gana la regresión: se equivoca en promedio un 4,89 %, frente a un 6 % de Holt–Winters, y explica el 76,73 % de la variación. Con ese modelo pronostican 36 meses hacia adelante.»

La idea, explicada fácil

Regresión lineal múltiple: una fórmula que suma el efecto de varias variables, cada una con su peso. **Holt–Winters:** suaviza la serie y repite su tendencia y su estacionalidad, sin mirar ninguna otra variable. **Selección paso a paso (*stepwise*):** agregar o quitar variables de una en una y quedarse con las que mejoran el modelo.

Rúbrica: base para reproducir los objetivos del artículo. Holt–Winters aparece solo como referencia del artículo, no como modelo nuestro.

Diapositiva 4 de 16 · Nuestro problema: un panel de 5.400 filas

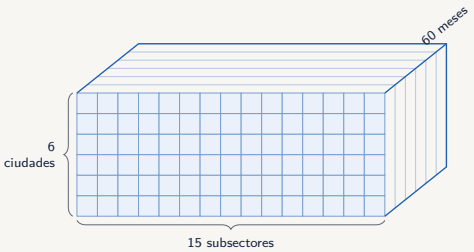
Joshua · 0:55

PLANTEAMIENTO EN COLOMBIA

Nuestro problema: un panel de 5.400 filas

- **Tarea:** regresión.
- **Objetivo:** ventas mensuales de muebles, en millones de USD.
- **Unidad:** un mes, en una ciudad, en un subsector.
- **9 predictoras:** importaciones, sentimiento del consumidor, inicios de vivienda, población, IPP, pandemia, ciudad, subsector y mes.

¿Por qué un panel? La guía pide 5.000 registros. Una serie nacional mensual necesitaría más de 400 años de historia.



60 × 6 × 15 = 5.400 filas

Proyecto Integrador · Machine Learning I · Bernal y Trujillo 4 / 16

Lo que dices

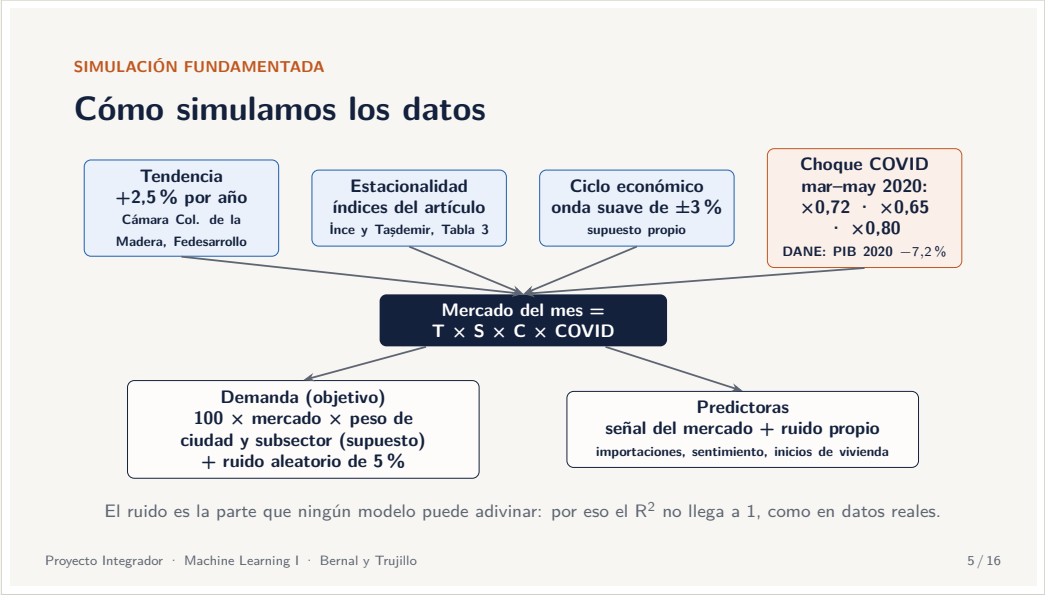
«Nosotros trasladamos ese objetivo a Colombia. Es un problema de regresión: queremos predecir las ventas mensuales de muebles, en millones de dólares. Pero había un reto: el artículo tiene solo 60 filas, y una serie nacional mensual nunca llegaría a 5.000 registros; harían falta más de 400 años de historia. Por eso cambiamos la unidad de observación: cada fila es un mes, en una ciudad y en un subsector. Son 60 meses por 6 ciudades por 15 subsectores: 5.400 filas. La pregunta de negocio es la misma, pero ahora hay datos suficientes para entrenar y validar. Usamos nueve predictoras: cinco indicadores nacionales, como las importaciones o el sentimiento del consumidor, la pandemia, la ciudad, el subsector y el mes.»

La idea, explicada fácil

Regresión: la respuesta es un número (ventas), no una categoría. **Panel:** una tabla que sigue a varias unidades, aquí ciudades y subsectores, a lo largo del tiempo. Es como tener 90 pequeñas tiendas observadas durante 60 meses, en lugar de una sola cifra nacional por mes.

Rúbrica: consolidación de los datos. Problema supervisado, variable objetivo y tamaño mínimo de 5.000 registros.

Diapositiva 5 de 16 · Cómo simulamos los datos Joshua · 1:10



Lo que dices

«Como no existe una base pública con este detalle para Colombia, hicimos una simulación fundamentada: cada pieza tiene un respaldo. Primero construimos el "mercado" de cada mes multiplicando cuatro componentes. Una tendencia de crecimiento del sector de 2,5 % al año, según la Cámara Colombiana de la Madera y Fedesarrollo. La estacionalidad, con los índices que publica el propio artículo. Un ciclo económico suave, que es un supuesto nuestro. Y el choque de la pandemia en marzo, abril y mayo de 2020, apoyado en la caída del PIB que reportó el DANE. De ese mercado salen dos cosas. La demanda, que es nuestra variable objetivo, con un peso según la ciudad y el subsector, que también es un supuesto nuestro, y un ruido aleatorio del 5 %. Y las predictoras, que son la señal del mercado más su propio ruido. Ese ruido es importante: impide que cualquier modelo adivine la fórmula exacta, como pasa con datos reales.»

La idea, explicada fácil

Simular con fundamento no es inventar números al azar: es reconstruir *cómo se generan* los datos (tendencia, estacionalidad, choques) con valores sacados de fuentes. **Estacionalidad multiplicativa:** cada mes vende un porcentaje fijo por encima o por debajo de lo normal; por ejemplo, diciembre vende un 5 % más, sea cual sea el nivel del mercado.

Rúbrica: consolidación de los datos. La guía pide mostrar cómo se generó la simulación y en qué evidencia se apoya.

Ojo: digan con claridad que el ciclo económico y los pesos por ciudad y subsector son supuestos propios. Ser transparentes con eso suma puntos.

Diapositiva 6 de 16 · La simulación reproduce la estructura temporal Joshua · 0:55



Lo que dices

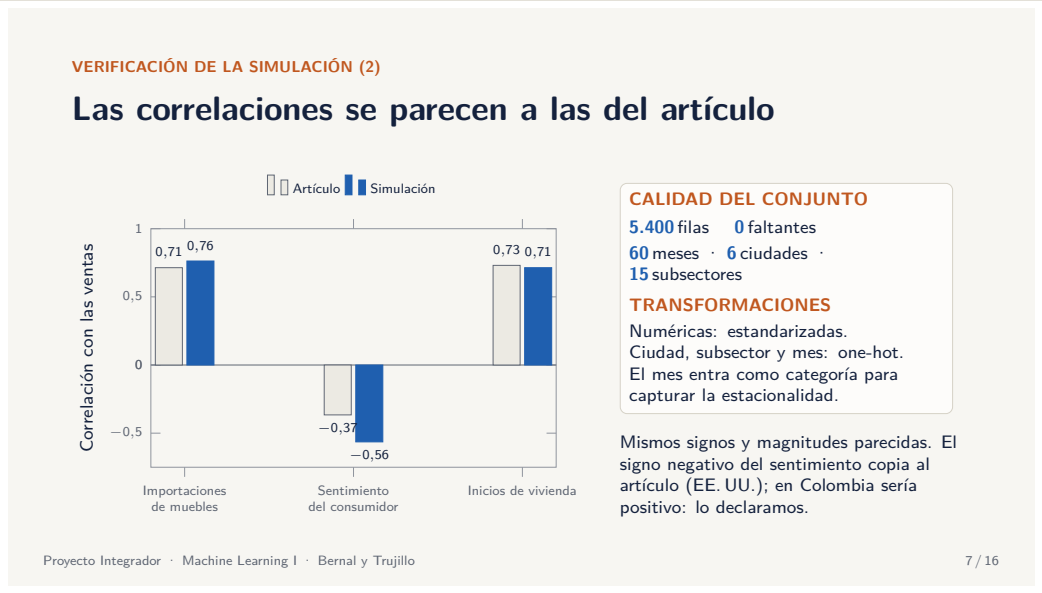
«La guía pide verificar que la simulación reproduce la estructura prevista. Aquí miramos el tiempo. A la izquierda está el promedio de ventas de cada mes: se ve la tendencia que sube, los picos que se repiten cada año y el hueco de la pandemia; en abril de 2020 las ventas caen un 31 % frente a abril de 2019. A la derecha comparamos la estacionalidad. La línea gris punteada es el índice del artículo y la azul es el que recuperamos de nuestros datos. Casi se montan una sobre otra: la diferencia máxima es de 0,019. Febrero es el mes más flojo, y noviembre y diciembre los más fuertes, igual que en el artículo.»

La idea, explicada fácil

Índice estacional: cuánto vende cada mes frente a un mes promedio; 1,05 significa 5 % más y 0,90, 10 % menos. Lo recuperamos dividiendo cada mes por la media móvil de 12 meses y promediando por mes del calendario, sin los meses de pandemia. Que coincida con el del artículo prueba que la simulación quedó bien construida.

Rúbrica: consolidación de los datos: verificación de la estructura (distribuciones y proporciones a lo largo del tiempo).

Diapositiva 7 de 16 · Las correlaciones se parecen a las del artículo Joshua · 1:00



Lo que dices

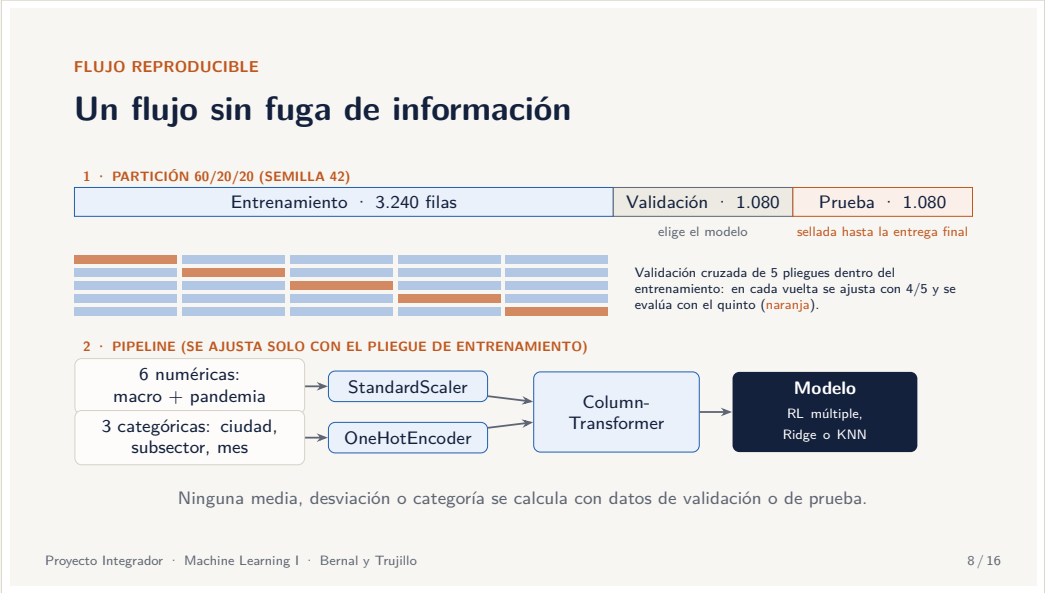
«Luego verificamos las relaciones. Las barras grises son las correlaciones que reporta el artículo y las azules las de nuestra simulación. Las importaciones de muebles y los inicios de vivienda se mueven con las ventas, con correlaciones cercanas a 0,7, como en el artículo, y el sentimiento del consumidor va en sentido contrario. Los signos coinciden y las magnitudes se parecen. La diferencia más grande está en el sentimiento, que nos quedó más fuerte: $-0{,}56$ frente a $-0{,}37$. Además, ese signo negativo lo copiamos del artículo, que es de Estados Unidos; en Colombia esperaríamos que la confianza del consumidor suba con las ventas, y lo dejamos como limitación. En calidad, el conjunto tiene 5.400 filas y ningún valor faltante. Las variables numéricas se estandarizan, y la ciudad, el subsector y el mes se codifican con one-hot; el mes entra como categoría para que el modelo capture la estacionalidad.»

La idea, explicada fácil

Correlación: mide, de -1 a 1, qué tanto se mueven juntas dos variables; el signo dice si van en la misma dirección o en direcciones opuestas. **One-hot:** convertir una categoría (Bogotá, Cali…) en columnas de ceros y unos para que el modelo pueda usarla. **Estandarizar:** poner todas las variables en la misma escala.

Rúbrica: consolidación de los datos: relaciones entre variables, calidad y transformaciones necesarias.

Diapositiva 8 de 16 · Un flujo sin fuga de información Santiago · 1:00



Lo que dices

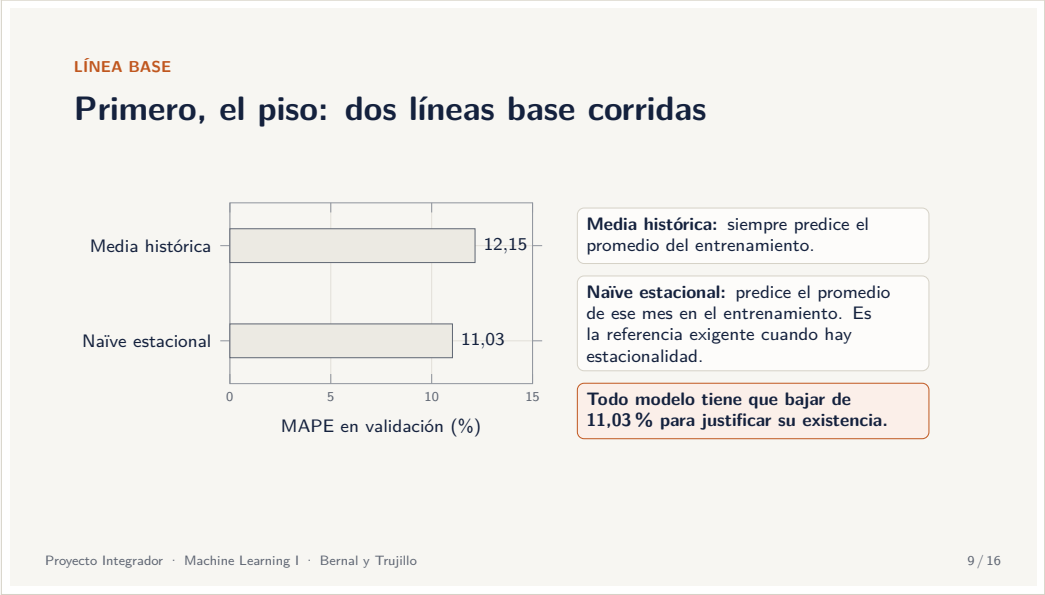
«Ahora, el flujo. Primero partimos los datos una sola vez, con semilla 42: 60 % para entrenar, 20 % para validar y 20 % para la prueba. La validación sirve para elegir el modelo, y la prueba queda sellada: no la tocamos hasta la entrega final. Dentro del entrenamiento hacemos validación cruzada de cinco pliegues: en cada vuelta el modelo aprende con cuatro partes y se evalúa con la quinta, la naranja. Todo el preprocesamiento va dentro de un Pipeline de scikit-learn: el escalamiento de las numéricas y el one-hot de las categóricas se ajustan en cada vuelta solo con los datos de entrenamiento. Así, ninguna media, ninguna desviación y ninguna categoría se calcula con datos que el modelo no debería ver. Eso es evitar la fuga.»

La idea, explicada fácil

Fuga de información: que el modelo, sin querer, vea el examen mientras estudia. Si la media para escalar se calcula con todos los datos, el examen ya influyó en el entrenamiento y la nota sale inflada. **Pipeline:** la receta completa (escalar, codificar, entrenar) empaquetada, para que se repita igual en cada vuelta sin que nadie la aplique a mano sobre todos los datos.

Rúbrica: flujo sin fuga. La guía pide explicar el orden de las etapas y por qué ese orden previene la fuga.

Diapositiva 9 de 16 · Primero, el piso: dos líneas base corridas Santiago · 0:35



Lo que dices

«Antes de los modelos, fijamos el piso con dos líneas base que construimos y corrimos. La primera predice siempre el promedio del entrenamiento y se equivoca un 12,15 %. La segunda es más exigente: para cada fila predice el promedio de ese mes en el entrenamiento, así que ya capta la estacionalidad; se equivoca un 11,03 %. Ese es el piso: un modelo que no baje de 11 % no justifica su complejidad.»

La idea, explicada fácil

Línea base: la respuesta más simple posible, sin aprender nada de las variables. Sirve de vara para medir: si un modelo no le gana a algo tan simple, no está aportando.

Rúbrica: entrenamiento y comparación. La guía exige comparar los modelos frente a la línea base.

Diapositiva 10 de 16 · Tres modelos y su ajuste por validación cruzada Santiago · 0:50

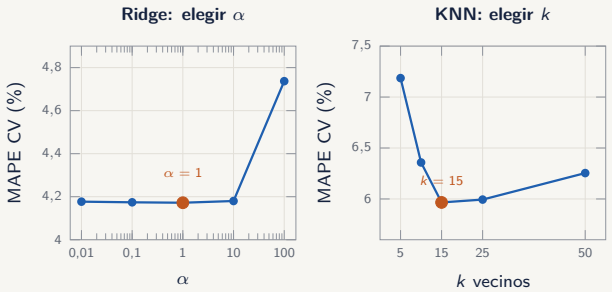
ENTRENAMIENTO

Tres modelos del curso y su ajuste por validación cruzada

Regresión lineal múltiple
Una recta con muchas variables. No tiene hiperparámetros.

Ridge
La misma recta, con coeficientes «frenados» por α.

KNN de regresión
Promedia las ventas de los k casos más parecidos.



Validación cruzada de 5 pliegues sobre el entrenamiento, con el MAPE como criterio.

Proyecto Integrador · Machine Learning I · Bernal y Trujillo 10 / 16

Lo que dices

«Comparamos tres modelos del curso. La regresión lineal múltiple, que es el mismo modelo del artículo. Ridge, que es esa misma regresión con un freno, alfa, que encoge los coeficientes para evitar el sobreajuste. Y KNN de regresión, que predice promediando las ventas de los k casos más parecidos. Los hiperparámetros los elegimos con validación cruzada. En Ridge, el error casi no cambia entre alfa 0,01 y 10, y empeora con 100; elegimos alfa igual a 1. En KNN, con pocos vecinos el modelo se deja llevar por el ruido y con muchos se vuelve demasiado general; el mejor punto es k igual a 15.»

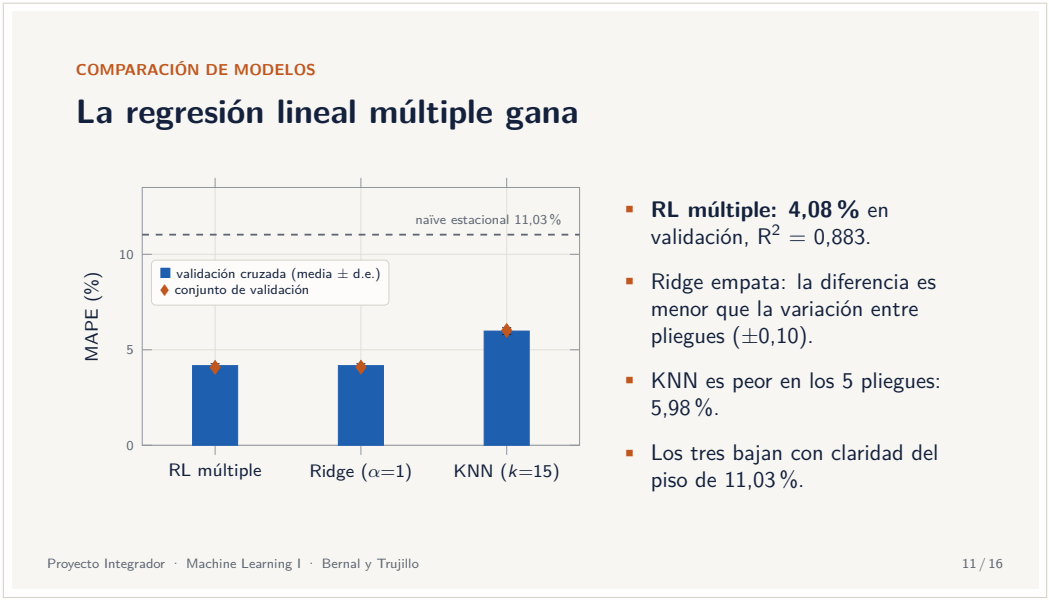
La idea, explicada fácil

Hiperparámetro: una perilla que se fija antes de entrenar. En Ridge, **alfa** dice qué tan fuerte frenamos los coeficientes; en KNN, k dice cuántos vecinos promediamos. Se eligen con validación cruzada, nunca mirando la prueba. Que el error de Ridge casi no cambie con alfa indica que la regresión no estaba sobreajustada.

Rúbrica: entrenamiento y comparación: ajuste inicial de hiperparámetros con validación cruzada.

Diapositiva 11 de 16 · La regresión lineal múltiple gana

Santiago · 0:55



Lo que dices

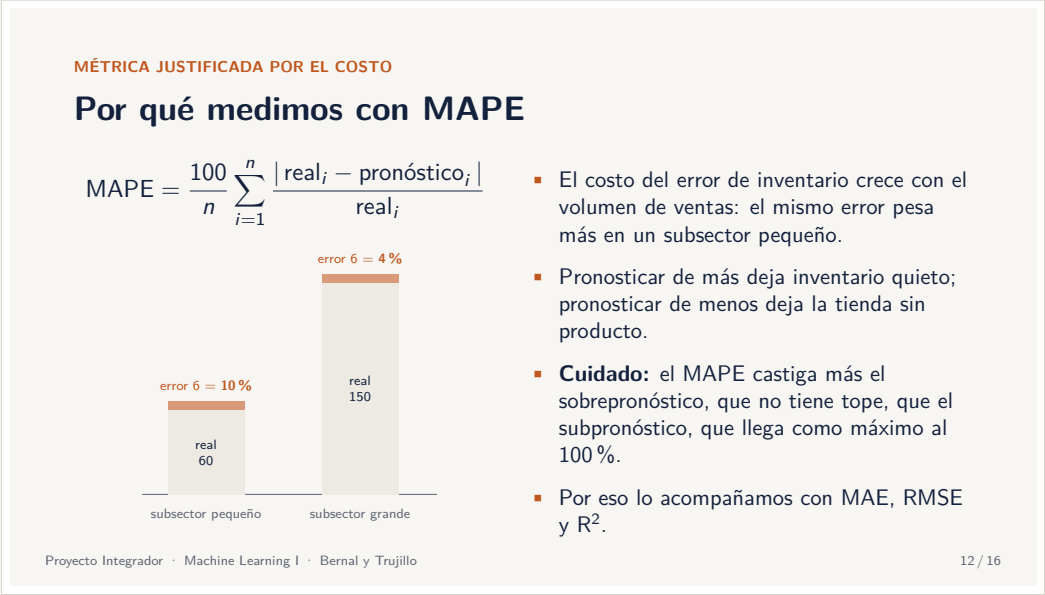
«Este es el resultado. Las barras son el error promedio en la validación cruzada, con su variación entre pliegues, y los rombos son el error en el conjunto de validación. La regresión lineal múltiple se equivoca un 4,08 % en validación y explica el 88 % de la variación. Ridge da prácticamente lo mismo: la diferencia es menor que lo que varía el error de un pliegue a otro, así que es ruido. KNN es peor en los cinco pliegues, con casi 6 %. Y los tres quedan muy por debajo de la línea base de 11 %. Por eso elegimos la regresión lineal múltiple: es la más precisa y además la más fácil de interpretar.»

La idea, explicada fácil

Media ± desviación: el promedio de los cinco pliegues y cuánto se mueve de uno a otro. Si dos modelos se diferencian menos que esa variación, no se puede decir que uno sea mejor; si uno gana en los cinco pliegues, como la regresión frente a KNN, la ventaja es real.

Rúbrica: entrenamiento y comparación sustentada en evidencia; resultados reportados con su variabilidad.

Diapositiva 12 de 16 · Por qué medimos con MAPE Santiago · 0:50



Lo que dices

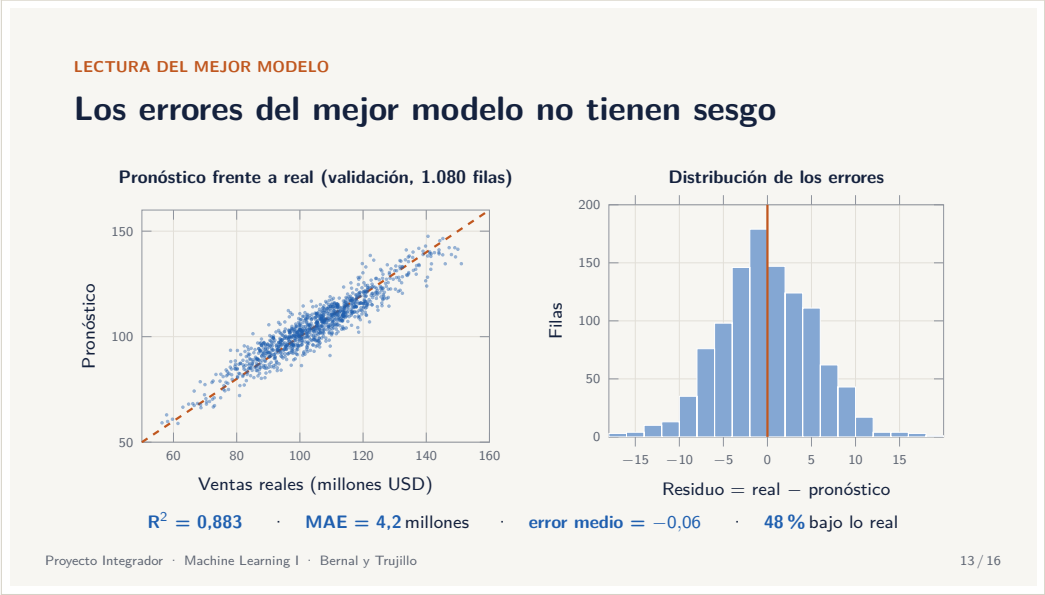
«¿Por qué medimos con el MAPE? Porque en inventario el costo de equivocarse depende del tamaño de las ventas. El MAPE mide el error como porcentaje de lo real. Miren el ejemplo: un error de 6 millones es un 10 % en un subsector que vende 60, pero solo un 4 % en uno que vende 150. Pronosticar de más deja inventario quieto; pronosticar de menos deja la tienda sin producto. Ahora, el MAPE tiene una trampa: castiga más el sobrepronóstico, que puede pasar del 100 %, que el subpronóstico, que nunca pasa de 100 %. Por eso no lo usamos solo: lo acompañamos con el MAE, el RMSE y el R^2.»

La idea, explicada fácil

MAE: error promedio en millones. **RMSE:** parecido, pero castiga más los errores grandes. **R^2:** qué parte de la variación explica el modelo; 1 sería perfecto y 0, nada. Cada métrica mira el error desde un ángulo distinto; por eso se reportan juntas.

Rúbrica: validación y métricas justificadas según el problema y el costo del error.

Diapositiva 13 de 16 · Los errores del mejor modelo no tienen sesgo Santiago · 0:55



Lo que dices

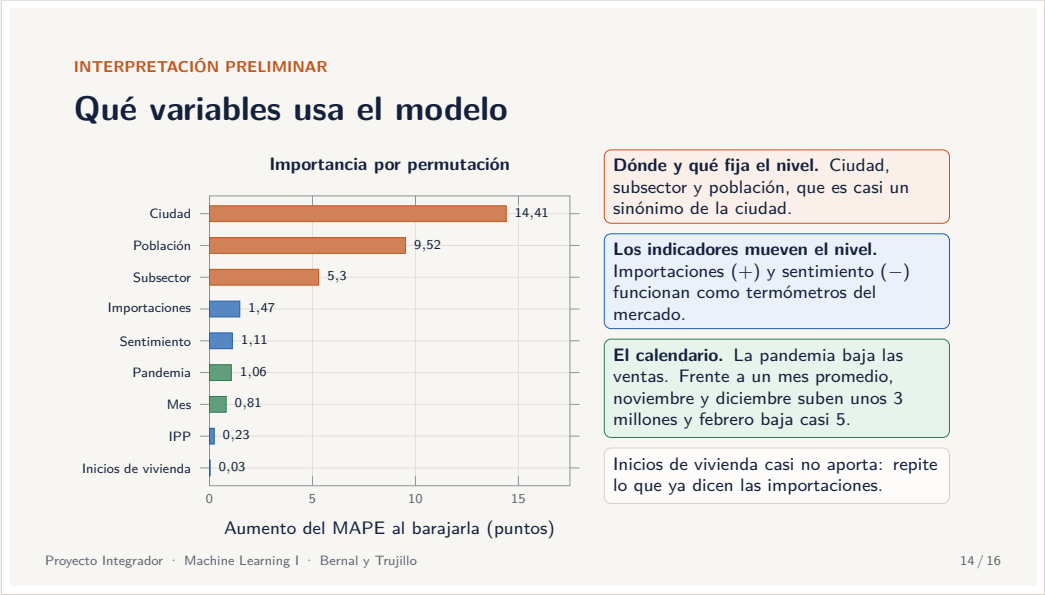
«Ahora leemos los errores del mejor modelo en las 1.080 filas de validación. A la izquierda, cada punto es una fila: en el eje horizontal lo que se vendió y en el vertical lo que pronosticamos. Los puntos se agrupan alrededor de la diagonal, que es el pronóstico perfecto. A la derecha están los residuos, es decir, real menos pronóstico: tienen forma de campana centrada en cero. El error medio es de $-0{,}06$ millones, prácticamente cero: el 48 % de los pronósticos queda por debajo de lo real y el 52 % por encima. El modelo no se equivoca sistemáticamente hacia un lado. En promedio se aleja 4,2 millones de lo real.»

La idea, explicada fácil

Residuo: lo que el modelo no logró explicar. **Sesgo:** equivocarse siempre hacia el mismo lado. Si los residuos están centrados en cero y sin forma rara (ni curva ni embudo), el modelo no tiene sesgo y la relación lineal es adecuada.

Rúbrica: interpretación preliminar: errores del mejor modelo.

Diapositiva 14 de 16 · Qué variables usa el modelo Santiago · 1:00



Lo que dices

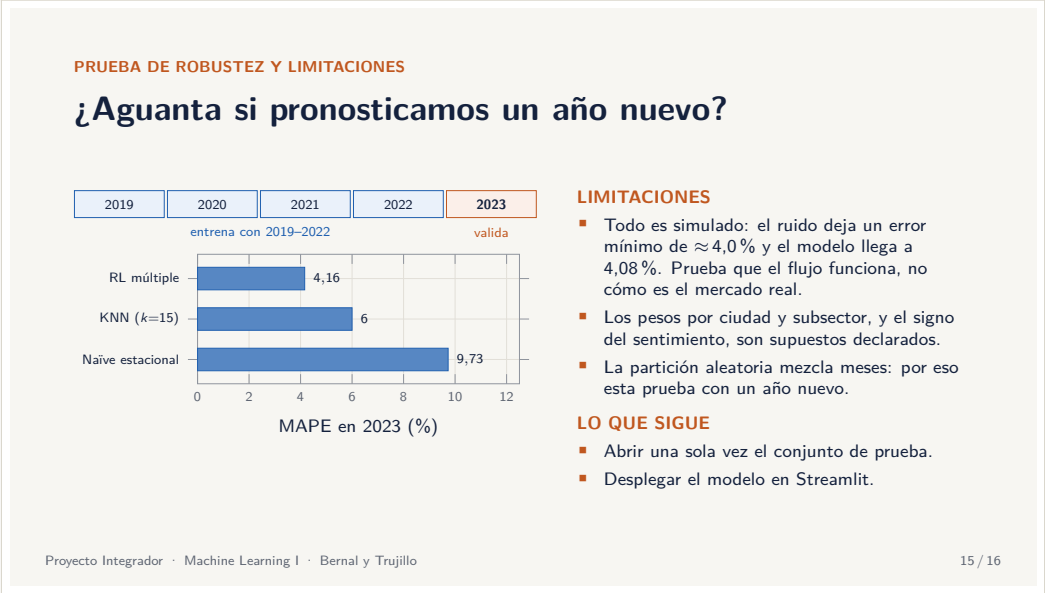
«¿Qué variables usa el modelo? Lo medimos con importancia por permutación: desordenamos una variable a la vez y vemos cuánto empeora el error. Si empeora mucho, el modelo dependía de ella. Hay tres grupos. Primero, dónde y qué: la ciudad, el subsector y la población, que en nuestros datos es casi un sinónimo de la ciudad; ellas fijan el nivel de ventas. Segundo, los indicadores: las importaciones suben con las ventas y el sentimiento del consumidor va al revés; funcionan como termómetros del mercado. Tercero, el calendario: la pandemia baja las ventas, y frente a un mes promedio, noviembre y diciembre suben unos 3 millones, mientras febrero baja casi 5. Los inicios de vivienda casi no aportan, porque repiten lo que ya dicen las importaciones.»

La idea, explicada fácil

Importancia por permutación: es como quitarle una herramienta a alguien y ver cuánto peor trabaja. **Colinealidad:** cuando dos variables cuentan la misma historia, el modelo usa una y la otra sobra; por eso inicios de vivienda pesa poco aunque esté correlacionada con las ventas.

Rúbrica: interpretación preliminar: variables relevantes e implicaciones.

Diapositiva 15 de 16 · ¿Aguanta si pronosticamos un año nuevo? Santiago · 1:05



Lo que dices

«Hicimos una prueba extra. Como la partición aleatoria mezcla meses, quisimos ver qué pasa si pronosticamos un año que el modelo nunca vio: entrenamos con 2019 a 2022 y validamos con todo 2023. La regresión lineal se equivoca un 4,16 %, casi igual que antes; KNN, un 6 %, y la línea base, casi un 10 %. El resultado se sostiene. También somos claros con las limitaciones: todos los datos son simulados. Con el ruido que pusimos, el menor error posible es de un 4 %, y el modelo llega a 4,08 %: está prácticamente en el techo. Eso demuestra que el flujo funciona y no tiene fuga, pero no prueba cómo se comporta el mercado real. Además, las variables económicas están muy correlacionadas entre sí. Para la entrega final abriremos una sola vez el conjunto de prueba y desplegaremos el modelo en Streamlit.»

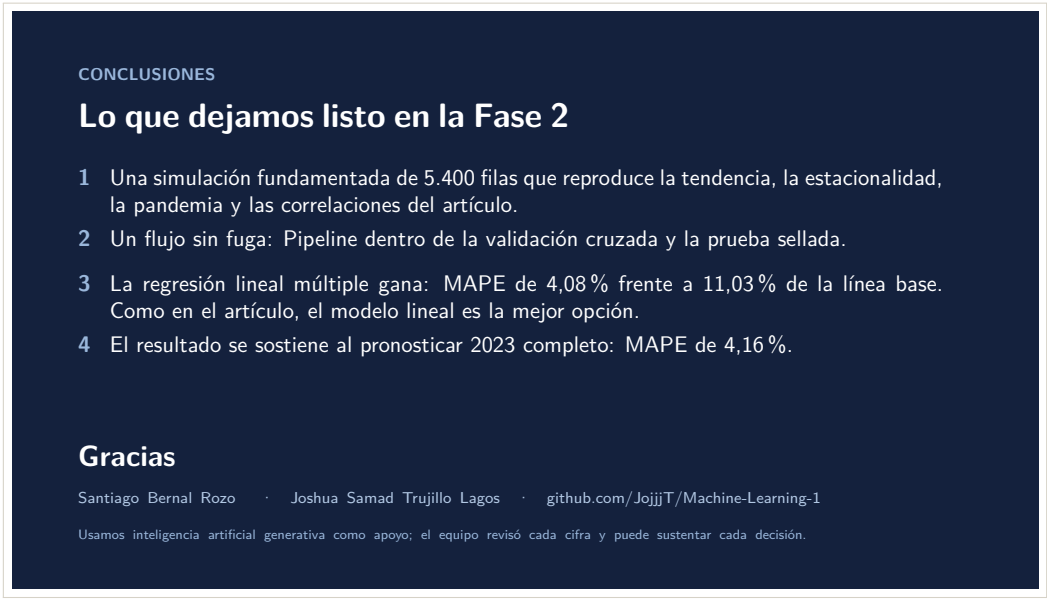
La idea, explicada fácil

Validación temporal: entrenar con el pasado y evaluar con el futuro, que es como se usaría el modelo en la vida real. Con la partición aleatoria, filas del mismo mes caen en entrenamiento y en validación; con esta prueba eso no pasa, y el error casi no cambia. **Techo:** si un modelo conociera la fórmula exacta de la simulación, todavía fallaría por el ruido, en promedio un 4 %. Decirlo antes de que lo pregunte el profesor responde la objeción de que «el modelo solo aprende lo que ustedes simularon».

Rúbrica: validación adecuada y discusión honesta de los límites.

Diapositiva 16 de 16 · Conclusiones

Los dos · 0:50



Lo que dices

Joshua: «Cerramos. Primero, construimos una simulación fundamentada de 5.400 filas que reproduce la tendencia, la estacionalidad, la pandemia y las correlaciones del artículo. Segundo, el flujo no tiene fuga: todo el preprocesamiento va dentro del Pipeline y la prueba sigue sellada.»
Santiago: «Tercero, la regresión lineal múltiple es el mejor modelo, con 4,08 % de error frente al 11 % de la línea base; igual que en el artículo, el modelo lineal es la mejor opción. Y cuarto, el resultado se sostiene al pronosticar un año completo nuevo. Usamos inteligencia artificial como apoyo y lo declaramos; revisamos cada cifra y podemos sustentar cada decisión. Gracias.»

La idea, explicada fácil

El cierre repite las cuatro ideas que el profesor debe recordar: datos bien construidos, flujo sin fuga, un ganador claro frente a la línea base y un resultado que aguanta una prueba más dura. La declaración de uso de IA es obligatoria según la guía.

Rúbrica: comunicación: dominio de los dos integrantes y cierre claro.

Glosario fácil

Pronóstico	Estimar un valor futuro; aquí, las ventas de muebles.
Regresión	Modelo cuya respuesta es un número.
Panel	Tabla que sigue a varias unidades (ciudades y subsectores) a lo largo del tiempo.
Simulación fundamentada	Datos generados con una estructura y unos valores respaldados por fuentes.
Estacionalidad	Patrón que se repite cada año (diciembre alto, febrero bajo).
Correlación	Qué tanto se mueven juntas dos variables, de -1 a 1.
Estandarizar	Restar la media y dividir por la desviación, para poner las variables en la misma escala.
One-hot	Convertir una categoría en columnas de ceros y unos.
Fuga de información	Que el modelo use, al entrenar, datos que no debería ver. Infla las métricas.
Pipeline	La secuencia completa de preprocesamiento y modelo, que se ajusta junta.
Validación cruzada	Partir el entrenamiento en k pliegues y evaluar k veces, cada vez con un pliegue distinto.
Conjunto de prueba	Datos guardados para evaluar una sola vez al final.
Línea base	La predicción más simple; el piso que todo modelo debe superar.
Hiperparámetro	Ajuste que se fija antes de entrenar (α en Ridge, k en KNN).
Ridge	Regresión lineal que encoge los coeficientes para evitar el sobreajuste.
KNN	Predice con el promedio de los k casos más parecidos.
Sobreajuste	Aprenderse los datos de entrenamiento de memoria y fallar con datos nuevos.
MAPE	Error promedio como porcentaje de lo real.
MAE y RMSE	Error promedio en millones; el RMSE castiga más los errores grandes.
R^2	Parte de la variación que explica el modelo (de 0 a 1).
Residuo	Real menos pronóstico.
Sesgo	Equivocarse siempre hacia el mismo lado.
Importancia por permutación	Cuánto empeora el modelo al desordenar una variable.
Colinealidad	Cuando dos predictoras cuentan casi la misma información.
Validación temporal	Entrenar con el pasado y evaluar con un periodo posterior.

Lista final antes de grabar y entregar

El informe corregido, el repositorio y el video ya dicen lo mismo: partición aleatoria, figuras con la validación, prueba sellada, ajuste de α y k, validación con 2023 y declaración de uso de IA.

Antes de grabar

- Cada uno leyó «La idea» de todas las diapositivas, no solo las suyas: el profesor puede preguntarle a cualquiera.
- Ensayaron una vez completa con cronómetro: unos 14 minutos, nunca más de 15.
- Audio revisado en una prueba de 20 segundos.

Al grabar

- Joshua: diapositivas 1 a 7. Santiago: 8 a 15. Los dos: la 16.
- Presentación en pantalla completa; señalen con el cursor lo que explican.
- Hablen con sus palabras; el guion es la guía, no un texto para leer.

Antes de entregar

- Subieron al repositorio los archivos de `correcciones_repositorio.zip`: informe, README, figuras y los dos scripts nuevos.
- El README ya dice Santiago Bernal Rozo y Joshua Samad Trujillo Lagos.
- Entregan el video junto con el informe corregido y el enlace del repositorio.