PROYECTO INTEGRADOR · SEGUNDA ENTREGA

Pronóstico de la demanda minorista de muebles en Colombia

Fase 2: datos, modelamiento y validación

Reproducción de İnce y Taşdemir (2024) con modelos de Machine Learning I



Santiago Bernal Rozo · **Joshua Samad Trujillo Lagos**

Machine Learning I · Prof. Alber Montenegro · Universidad Externado de Colombia · 2026

Código: github.com/JojjjT/Machine-Learning-1

PUNTO DE PARTIDA

Qué corregimos frente a la primera entrega

	Antes	Ahora
Tamaño	60 observaciones mensuales	Panel mes × ciudad × subsector: **5.400 filas**
Modelos	Holt–Winters y otros fuera del curso	Solo regresión lineal múltiple, Ridge y KNN
Código	No había código ejecutable	Scripts reproducibles con semilla 42
Línea base	Solo descrita	Construida y corrida: **MAPE 11,03 %**
Métrica	MAPE «porque es lo usual»	MAPE justificado por el costo del inventario

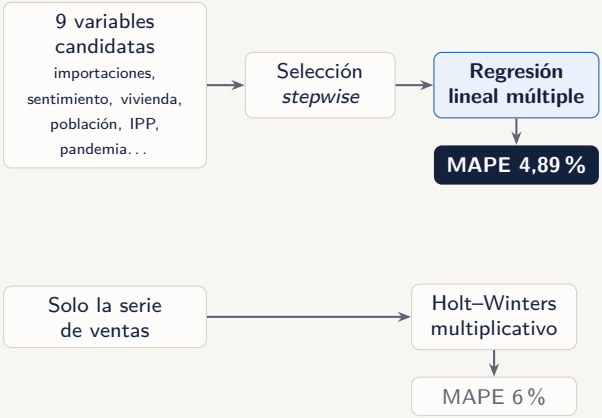
Los cinco puntos salen de la retroalimentación de la primera entrega.

El artículo: regresión lineal frente a Holt–Winters

İnce y Taşdemir (2024), *Systems*, 12(6), 219

- Ventas minoristas mensuales de muebles en EE. UU.
- 60 meses, de 2019 a 2023, con la pandemia adentro.
- Nueve variables candidatas; la selección *stepwise* deja las útiles.
- Pronóstico a 36 meses (2024–2026).

Conclusión: la regresión lineal múltiple predice mejor ($R^2 = 76{,}73\,\%$).



Nuestro problema: un panel de 5.400 filas

- **Tarea:** regresión.
- **Objetivo:** ventas mensuales de muebles, en millones de USD.
- **Unidad:** un mes, en una ciudad, en un subsector.
- **9 predictoras:** importaciones, sentimiento del consumidor, inicios de vivienda, población, IPP, pandemia, ciudad, subsector y mes.

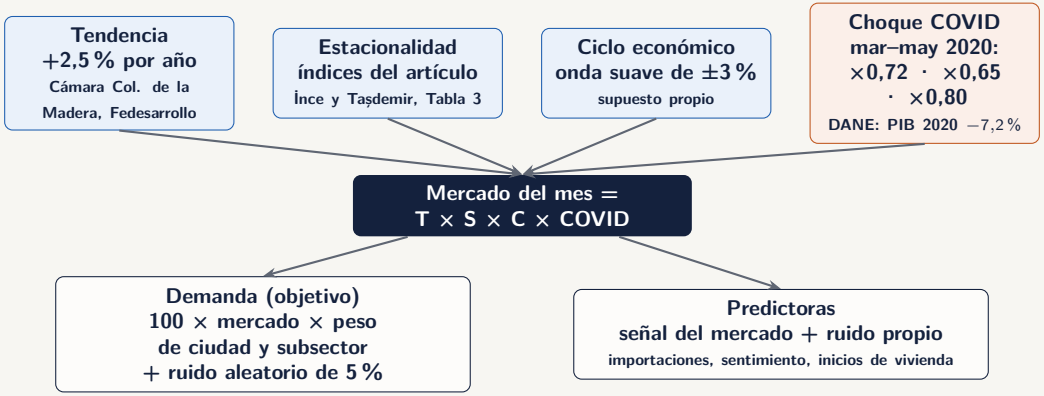
¿Por qué un panel? La guía pide 5.000 registros. Una serie nacional mensual necesitaría más de 400 años de historia.



60 × 6 × 15 = 5.400 filas

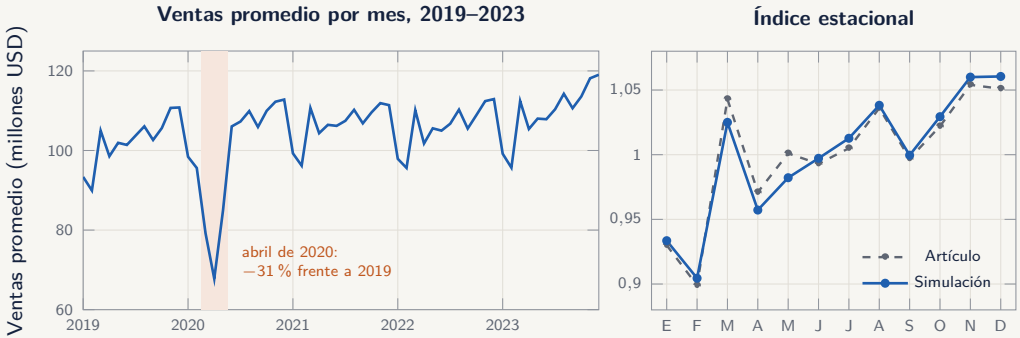
SIMULACIÓN FUNDAMENTADA

Cómo simulamos los datos



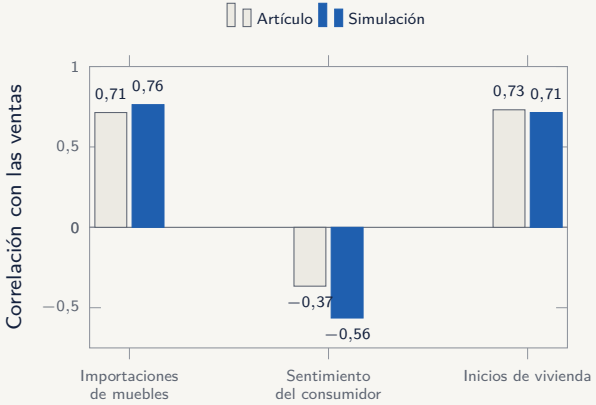
El ruido es la parte que ningún modelo puede adivinar: por eso el R^2 no llega a 1, como en datos reales.

La simulación reproduce la estructura temporal



El índice recuperado de los datos difiere como máximo 0,019 del publicado en el artículo.

Las correlaciones se parecen a las del artículo



CALIDAD DEL CONJUNTO

5.400 filas **0** faltantes
60 meses · **6** ciudades · **15** subsectores

TRANSFORMACIONES

Numéricas: estandarizadas.
Ciudad, subsector y mes: one-hot.
El mes entra como categoría para capturar la estacionalidad.

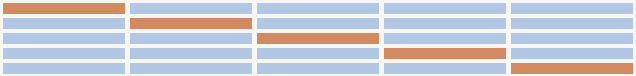
Mismos signos y magnitudes parecidas. El sentimiento quedó más fuerte que en el artículo ($-0{,}56$ frente a $-0{,}37$).

FLUJO REPRODUCIBLE

Un flujo sin fuga de información

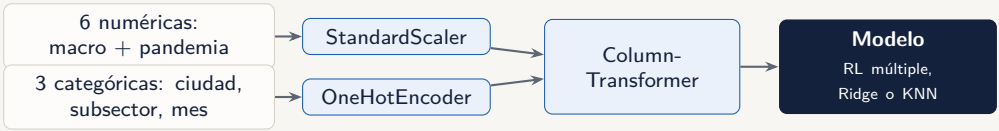
1 · PARTICIÓN 60/20/20 (SEMILLA 42)

Entrenamiento · 3.240 filas	Validación · 1.080	Prueba · 1.080
	elige el modelo	sellada hasta la entrega final



Validación cruzada de 5 pliegues dentro del entrenamiento: en cada vuelta se ajusta con 4/5 y se evalúa con el quinto (naranja).

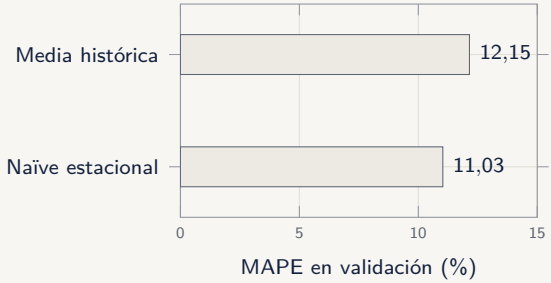
2 · PIPELINE (SE AJUSTA SOLO CON EL PLIEGUE DE ENTRENAMIENTO)



Ninguna media, desviación o categoría se calcula con datos de validación o de prueba.

LÍNEA BASE

Primero, el piso: dos líneas base corridas



Media histórica: siempre predice el promedio del entrenamiento.

Naïve estacional: predice el promedio de ese mes en el entrenamiento. Es la referencia exigente cuando hay estacionalidad.

Todo modelo tiene que bajar de 11,03 % para justificar su existencia.

ENTRENAMIENTO

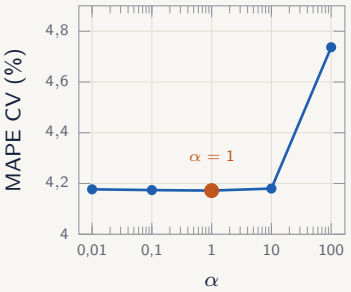
Tres modelos del curso y su ajuste por validación cruzada

Regresión lineal múltiple
Una recta con muchas variables. No tiene hiperparámetros.

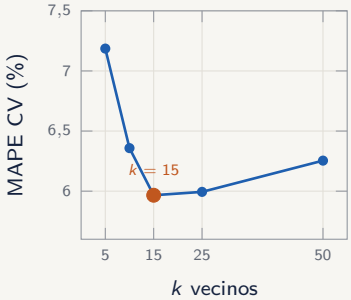
Ridge
La misma recta, con coeficientes «frenados» por α.

KNN de regresión
Promedia las ventas de los k casos más parecidos.

Ridge: elegir α



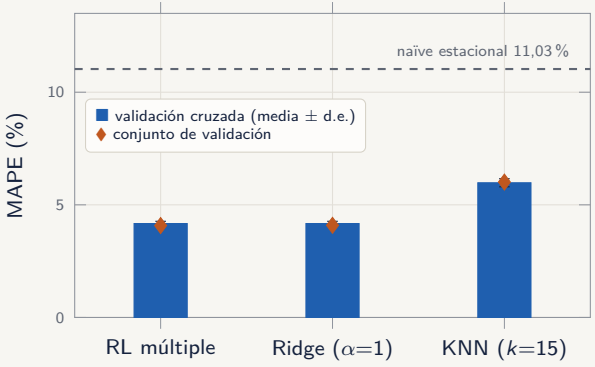
KNN: elegir k



Validación cruzada de 5 pliegues sobre el entrenamiento, con el MAPE como criterio.

COMPARACIÓN DE MODELOS

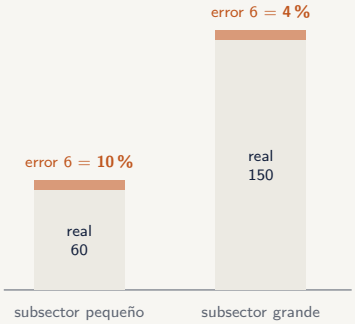
La regresión lineal múltiple gana



- **RL múltiple: 4,08 %** en validación, $R^2 = 0{,}883$.
- Ridge empata: la diferencia es menor que la variación entre pliegues ($\pm 0{,}10$).
- KNN es peor en los 5 pliegues: 5,98 %.
- Los tres bajan con claridad del piso de 11,03 %.

Por qué medimos con MAPE

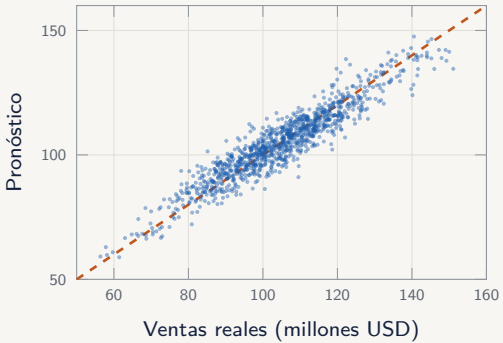
$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^{n} \frac{|\,\text{real}_i - \text{pronóstico}_i\,|}{\text{real}_i}$$



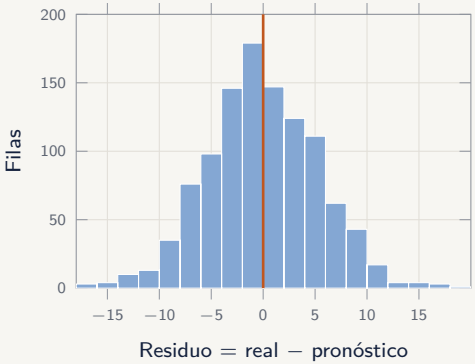
- El costo del error de inventario crece con el volumen de ventas: el mismo error pesa más en un subsector pequeño.
- Pronosticar de más deja inventario quieto; pronosticar de menos deja la tienda sin producto.
- **Cuidado:** el MAPE castiga más el sobrepronóstico, que no tiene tope, que el subpronóstico, que llega como máximo al 100 %.
- Por eso lo acompañamos con MAE, RMSE y R^2.

Los errores del mejor modelo no tienen sesgo

Pronóstico frente a real (validación, 1.080 filas)

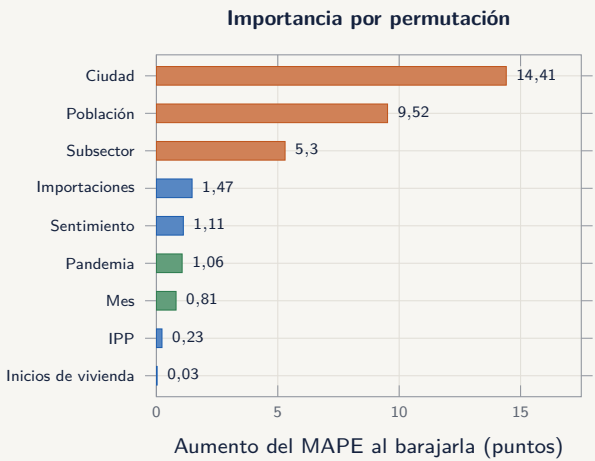


Distribución de los errores



$R^2 = 0{,}883$ · **MAE = 4,2** millones · **error medio = −0,06** · **48 %** bajo lo real

Qué variables usa el modelo



Dónde y qué fija el nivel. Ciudad, subsector y población, que es casi un sinónimo de la ciudad.

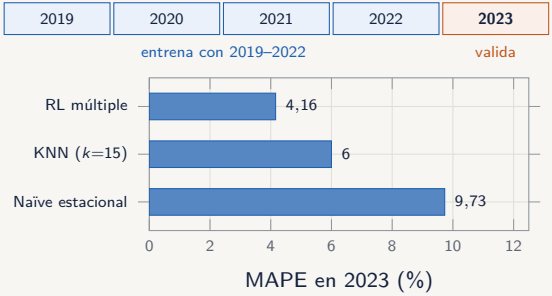
Los indicadores mueven el nivel. Importaciones (+) y sentimiento (−) funcionan como termómetros del mercado.

El calendario. La pandemia baja las ventas. Frente a un mes promedio, noviembre y diciembre suben unos 3 millones y febrero baja casi 5.

Inicios de vivienda casi no aporta: repite lo que ya dicen las importaciones.

PRUEBA DE ROBUSTEZ Y LIMITACIONES

¿Aguanta si pronosticamos un año nuevo?



LIMITACIONES

- Los datos son simulados: los resultados dependen de los supuestos.
- La partición aleatoria mezcla meses; por eso hicimos esta prueba con un año completo nuevo.
- Las variables macro están muy correlacionadas entre sí.

LO QUE SIGUE

- Abrir una sola vez el conjunto de prueba.
- Desplegar el modelo en Streamlit.

CONCLUSIONES

Lo que dejamos listo en la Fase 2

1. Una simulación fundamentada de 5.400 filas que reproduce la tendencia, la estacionalidad, la pandemia y las correlaciones del artículo.
2. Un flujo sin fuga: Pipeline dentro de la validación cruzada y la prueba sellada.
3. La regresión lineal múltiple gana: MAPE de 4,08 % frente a 11,03 % de la línea base. Como en el artículo, el modelo lineal es la mejor opción.
4. El resultado se sostiene al pronosticar 2023 completo: MAPE de 4,16 %.

Gracias

Santiago Bernal Rozo · Joshua Samad Trujillo Lagos · github.com/JojjjT/Machine-Learning-1

Usamos inteligencia artificial generativa como apoyo; el equipo revisó cada cifra y puede sustentar cada decisión.